

# Analyse en Composante Principale (ACP)

# Plan du cours

## Analyse en Composante Principale (ACP)

1. Définitions, applications et objectifs de l'ACP
2. Notion de covariance et ACP non-normée
3. Notion de corrélation et ACP normée
4. Mécanique de l'ACP à partir d'un exemple à deux variables
5. Application à partir d'un exemple concret (les forêts françaises)

# Plan du cours

## Analyse en Composante Principale (ACP)

1. Définitions, applications et objectifs de l'ACP
2. Notion de covariance et ACP non-normée
3. Notion de corrélation et ACP normée
4. Mécanique de l'ACP à partir d'un exemple à deux variables
5. Application à partir d'un exemple concret (les forêts françaises)

# Statistique multi-variée

## ➤ Méthodes descriptives ( $X_j$ ) :

- $X_j$  quantitatives : Analyse en Composante Principale (ACP)
- $X_j$  qualitatives : Analyse Factorielle des Correspondances (AFC)
- ...


## ➤ Méthodes explicatives ( $Y_k = f(X_j)$ ) :

- $Y_k$  et  $X_j$  quantitatives : Analyse Canonique des Corrélations (ACC)
- $Y_k$  qualitatives et  $X_j$  quantitatives : Analyse Discriminante (AFD)
- ...

# Principe de l'ACP

➤ Représenter au mieux dans un espace plus réduit des observations issues d'un espace plus grand en nombres de dimensions ( $X_j$  variables) :


- Simplification de la réalité
- Concentration d'une information de départ diluée
- Description du maximum de variabilité dans un espace réduit



# Principe de l'ACP

## ➤ Dessinez c'est gagné?

- Simplifier un objet 3D (réalité) par une représentation en 2D (plan)





# Quelles applications?

## ➤ Analyses de données :

- Réduction du nombres de variables explicatives ( $X_j$ ) avant modélisation
- Obtention de nouvelles variables explicatives ( $CP_j$ ) non corrélées

## ➤ Imagerie :

- Compression d'image
- Reconnaissance faciale



# Situation

- **$P$  variables quantitatives ont été mesurées sur  $N$  individus :**

	$X_1$	$X_2$	...	$X_j$	...	$X_p$
<i>ind 1</i>	$x_{11}$	$x_{11}$	...	$x_{1j}$	...	$x_{1p}$
<i>ind 2</i>	$x_{12}$	$x_{22}$	...	$x_{2j}$	...	$x_{2p}$
...	...	...	...	...	...	...
<i>ind i</i>	$x_{i1}$	$x_{i2}$	...	$x_{ij}$	...	$x_{ip}$
...	...	...	...	...	...	...
<i>ind n</i>	$x_{n1}$	$x_{n2}$	...	$x_{nj}$	...	$x_{np}$



- **Q : Peut-on « simplifier », « concentrer » ou « compresser » l'essentiel de l'information contenue dans ce tableau?**
- **Exemple : Mesures de  $P$  variables morpho-métriques sur  $N$  individus différents**

# Objectifs

- Résumer le tableau de façon à identifier les variables ou combinaisons de variables selon lesquelles les  $N$  individus se différencient le plus
  - Identification des « composantes principales » (CP) qui déterminent l'essentiel de la différence entre individus (variance)
- Examiner la position des  $N$  individus le long de ces « composantes principales »
  - Typologie des individus
- Etudier les relations des  $P$  variables le long de ces « composantes principales »
  - Typologie des variables

# Notion de projection



- Cas simple d'un tableau à 2 variables ( $P = 2$ ,  $X_1$  et  $X_2$ ) et  $N$  individus :
  - On pourrait résumer ce tableau par une « composante principale »  $CP_1$ ,
  - Projection orthogonale des individus le long de  $CP_1$ ,



- Orthogonalité de  $CP_2$  par rapport à  $CP_1$ ,
- Changement de référentiel obtenu par rotation

# Centrage

- Il est recommandé de toujours centrer les valeurs associées à chaque variable  $X_j$  pour éviter le problème de la translation au cours du changement de référentiel et pour simplifier au cas de la rotation seule



- Comment allez-vous positionner  $CP_1$ , puis  $CP_2$ ?

# Plan du cours

## Analyse en Composante Principale (ACP)

1. Définitions, applications et objectifs de l'ACP
2. Notion de covariance et ACP non-normée
3. Notion de corrélation et ACP normée
4. Mécanique de l'ACP à partir d'un exemple à deux variables
5. Application à partir d'un exemple concret (les forêts françaises)

# Notion de covariance

- ACP : calculs des CPs basés sur la covariance entre variables
- Qu'est ce que la covariance entre deux variables  $X_1$  et  $X_2$ ?
  - Indique si à un écart positif de  $X_1$  pour un individu  $i$  par rapport à la moyenne sur  $X_1$ , correspond un écart positif ou négatif de  $X_2$  pour ce même individu  $i$  par rapport à la moyenne sur  $X_2$

$$\text{cov}(X_1, X_2) = \frac{\sum_{i=1}^n (X_{i,1} - \bar{X}_1)(X_{i,2} - \bar{X}_2)}{n-1}$$

$$\text{cov}(X_1, X_1) = ?$$


- C'est le signe de la covariance qui importe :

- $\text{cov}(X_1, X_2) > 0$  :  $X_1$  augmente quand  $X_2$  augmente
- $\text{cov}(X_1, X_2) < 0$  :  $X_1$  augmente quand  $X_2$  diminue

- NB : Si  $X_1$  et  $X_2$  sont centrées, alors  $\bar{X}_1 = \bar{X}_2 = 0$

# Notion de covariance

➤ Visualisation graphique de la covariance sur variables centrées :



$$\text{cov}(X_1, X_2) = 0.61 > 0$$

# Notion de covariance

➤ Pour  $P > 2$ , on calcule la covariance pour toutes les paires de variables possibles :

- Matrice  $C$  de covariances

$$C = \begin{pmatrix} \text{var}(X_1) & \text{cov}(X_1, X_2) & \dots & \text{cov}(X_1, X_j) & \dots & \text{cov}(X_1, X_p) \\ \text{cov}(X_2, X_1) & \text{var}(X_2) & \dots & \text{cov}(X_2, X_j) & \dots & \text{cov}(X_2, X_p) \\ \dots & \dots & \dots & \dots & \dots & \dots \\ \text{cov}(X_j, X_1) & \text{cov}(X_j, X_2) & \dots & \text{var}(X_j) & \dots & \text{cov}(X_j, X_p) \\ \dots & \dots & \dots & \dots & \dots & \dots \\ \text{cov}(X_p, X_1) & \text{cov}(X_p, X_2) & \dots & \text{cov}(X_p, X_j) & \dots & \text{var}(X_p) \end{pmatrix}$$

➤ Propriétés :

- $C$  est une matrice carré de taille  $p \times p$
- $C$  est une matrice symétrique

# Plan du cours

## Analyse en Composante Principale (ACP)

1. Définitions, applications et objectifs de l'ACP
2. Notion de covariance et ACP non-normée
3. Notion de corrélation et ACP normée
4. Mécanique de l'ACP à partir d'un exemple à deux variables
5. Application à partir d'un exemple concret (les forêts françaises)

# Notion de corrélation : l'ACP normée


## ➤ Corrélation = covariance « standardisée » : réduction

- Comprise entre -1 et 1, la corrélation mesure l'intensité de la liaison linéaire entre deux variables  $X_1$  et  $X_2$

$$\rho(X_1, X_2) = \frac{\text{cov}(X_1, X_2)}{\sigma(X_1)\sigma(X_2)}$$

$$\rho(X_1, X_1) = \frac{\text{cov}(X_1, X_1)}{\sigma(X_1)\sigma(X_1)}$$

$$\rho(X_1, X_1) = \frac{\text{var}(X_1)}{\text{var}(X_1)}$$



➤ NB :  $\rho^2$  = part de la variance partagée entre les 2 variables

# Notion de corrélation : ACP normée

➤ Si l'ACP est basée sur la matrice de covariances, l'ACP normée est basée elle sur la matrice de corrélations :

- Matrice  $C$  de corrélations

$$C = \begin{pmatrix} 1 & \rho(X_1, X_2) & \dots & \rho(X_1, X_j) & \dots & \rho(X_1, X_p) \\ \rho(X_2, X_1) & 1 & \dots & \rho(X_2, X_j) & \dots & \rho(X_2, X_p) \\ \dots & \dots & \dots & \dots & \dots & \dots \\ \rho(X_j, X_1) & \rho(X_j, X_2) & \dots & 1 & \dots & \rho(X_j, X_p) \\ \dots & \dots & \dots & \dots & \dots & \dots \\ \rho(X_p, X_1) & \rho(X_p, X_2) & \dots & \rho(X_p, X_j) & \dots & 1 \end{pmatrix}$$

➤ Propriétés :

- $C$  est une matrice carré de taille  $p \times p$
- $C$  est une matrice symétrique
- $C$  possède une diagonale de 1

# ACP non-normée ou ACP normée?

- **S'il est recommandé de toujours « centrer » ses données en ACP, la question de les « réduire » (ACP normée) dépend de vos données :**
  - Si vos données sont toutes dans la même unité de mesure et varient dans des gammes de valeurs identiques : l'ACP non-normée suffit
  - Si vos données sont dans des unités de mesure différentes et varient dans des gammes de valeurs différentes : l'ACP normée est recommandée

# Plan du cours

## Analyse en Composante Principale (ACP)

1. Définitions, applications et objectifs de l'ACP
2. Notion de covariance et ACP non-normée
3. Notion de corrélation et ACP normée
4. Mécanique de l'ACP à partir d'un exemple à deux variables
5. Application à partir d'un exemple concret (les forêts françaises)

# Un cas simple à 2 variables


➤ Reprenons le cas simple de notre exemple à deux variables  $X_1$  et  $X_2$  :

- $> X_1 = c(2.5, 0.5, 2.2, 1.9, 3.1, 2.3, 2, 1, 1.5, 1.1)$
- $> X_2 = c(2.4, 0.7, 2.9, 2.2, 3, 2.7, 1.6, 1.1, 1.6, 0.9)$

➤  $X_1$  et  $X_2$  varient d'un même ordre de grandeur?

- $\text{var}(X_1) = 0.6165556$
- $\text{var}(X_2) = 0.7165556$
- $\text{cov}(X_1, X_2) = 0.6154444$
- ACP non-normée = matrice de covariances

$$C = \begin{pmatrix} 0.6165556 & 0.6154444 \\ 0.6154444 & 0.7165556 \end{pmatrix}$$



➤ Utilisation de la matrice de covariances pour changer de référentiel :

- Calcul du vecteur directeur de  $CP_1$
- Calcul du vecteur directeur de  $CP_2$

# Un cas simple à 2 variables

## ➤ Une histoire d'algèbre linéaire et de calculs matriciels :

- Détermination des  $p$  valeurs propres  $\lambda_j$
- Détermination des  $p$  vecteurs propres  $V_j$

## ➤ Soit la matrice de covariances $C$ de taille $p \times p$ , elle admet $p$ valeurs propres et $p$ vecteurs propres associés, tels que :

- $CV_j = \lambda_j V_j$

## ➤ Dans notre exemple à deux variables, C admet 2 valeurs propres et 2 vecteurs propres tels que soit vérifié les égalités suivantes :

$$\begin{pmatrix} 0.6165556 & 0.6154444 \\ 0.6154444 & 0.7165556 \end{pmatrix} \begin{pmatrix} v_{1,1} \\ v_{1,2} \end{pmatrix} = \lambda_1 \begin{pmatrix} v_{1,1} \\ v_{1,2} \end{pmatrix}$$

$$\begin{pmatrix} 0.6165556 & 0.6154444 \\ 0.6154444 & 0.7165556 \end{pmatrix} \begin{pmatrix} v_{2,1} \\ v_{2,2} \end{pmatrix} = \lambda_2 \begin{pmatrix} v_{2,1} \\ v_{2,2} \end{pmatrix}$$

# Un cas simple à 2 variables

## ➤ Détermination des 2 valeurs propres $\lambda_1$ et $\lambda_2$ :

- Calcul du déterminant de  $C - \lambda I$
- Résolution de l'équation  $\det(C - \lambda I) = 0$

$$C - \lambda I = \begin{pmatrix} 0.6165556 & 0.6154444 \\ 0.6154444 & 0.7165556 \end{pmatrix} - \lambda \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$C - \lambda I = \begin{pmatrix} 0.6165556 - \lambda & 0.6154444 \\ 0.6154444 & 0.7165556 - \lambda \end{pmatrix}$$

$$\det(C - \lambda I) = (0.6165556 - \lambda)(0.7165556 - \lambda) - 0.6154444^2$$

$$\lambda^2 - 1.333111\lambda + 0.06302444 = 0$$

$$\Delta = b^2 - 4ac$$

$$\lambda_1 = \frac{-b + \sqrt{\Delta}}{2a} = 1.284028 \quad \lambda_2 = \frac{-b - \sqrt{\Delta}}{2a} = 0.04908323$$

# Un cas simple à 2 variables

- Chaque valeur propre représente la variance des données autour d'un nouvel axe  $CP$  ou « composante principale » qui est une combinaison linéaire des variables de départ

$$\lambda_1 + \lambda_2 = \text{var}(X_1) + \text{var}(X_2)$$

$$1.284028 + 0.04908323 = 0.6165556 + 0.7165556 = 1.333111$$

- La première « composante principale » ou  $CP_1$ , associée à  $\lambda_1$ , porte 96% de la variance totale
- La deuxième « composante principale » ou  $CP_2$  associée à  $\lambda_2$  porte 4% seulement de la variance totale
- A partir d'une seule dimension ( $CP_1$ ), il est possible ici de résumer 96% de l'information de départ contenue dans deux dimensions ( $X_1, X_2$ )

# Un cas simple à 2 variables

➤ Détermination des 2 vecteurs propres  $V_1$  et  $V_2$  :

- Résolution des 2 systèmes d'équations  $CV_j - \lambda_j V_j = 0$

$$\lambda_1 \begin{pmatrix} 0.6165556 & 0.6154444 \\ 0.6154444 & 0.7165556 \end{pmatrix} \begin{pmatrix} v_{1,1} \\ v_{1,2} \end{pmatrix} = 1.284028 \times \begin{pmatrix} v_{1,1} \\ v_{1,2} \end{pmatrix}$$

$$\begin{cases} 0.6165556 \times v_{1,1} + 0.6154444 \times v_{1,2} - 1.284028 \times v_{1,1} = 0 \\ 0.6154444 \times v_{1,1} + 0.7165556 \times v_{1,2} - 1.284028 \times v_{1,2} = 0 \end{cases}$$

$$\lambda_2 \begin{pmatrix} 0.6165556 & 0.6154444 \\ 0.6154444 & 0.7165556 \end{pmatrix} \begin{pmatrix} v_{2,1} \\ v_{2,2} \end{pmatrix} = 0.04908323 \times \begin{pmatrix} v_{2,1} \\ v_{2,2} \end{pmatrix}$$

$$\begin{cases} 0.6165556 \times v_{2,1} + 0.6154444 \times v_{2,2} - 0.04908323 \times v_{2,1} = 0 \\ 0.6154444 \times v_{2,1} + 0.7165556 \times v_{2,2} - 0.04908323 \times v_{2,2} = 0 \end{cases}$$

# Un cas simple à 2 variables

➤ Une solution possible (cf. sous la contrainte que  $V_1$  et  $V_2$  soient tout 2 des vecteurs unitaires de taille 1)

$$V_1 = \begin{pmatrix} 0.6778736 \\ 0.7351785 \end{pmatrix} \quad NB : v_{1,1}^2 + v_{1,2}^2 = 1$$

$$V_2 = \begin{pmatrix} -0.7351785 \\ 0.6778736 \end{pmatrix} \quad NB : v_{2,1}^2 + v_{2,2}^2 = 1$$



$$P = \begin{pmatrix} 0.6778736 & -0.7351785 \\ 0.7351785 & 0.6778736 \end{pmatrix}$$

$$D = \begin{pmatrix} 1.284028 & 0 \\ 0 & 0.04908323 \end{pmatrix}$$

$$C = PDP^t$$

# Un cas simple à 2 variables

- $V_1$  et  $V_2$  sont les vecteurs directeur de  $CP_1$  et  $CP_2$  :



- $CP_1$  porte 96% de l'inertie totale du nuage de point
- NB :  $\rho(X_1, X_2) = 0.93$  mais  $\rho(CP_1, CP_2) = 0$

# Un cas simple à 2 variables

➤ **L'information (variance) portée par CP1 est tellement importante que l'on peut se passer de CP2 :**

- Cela revient à compresser l'information originale portée par deux dimensions sur une seule dimension avec une perte ici de 4% de l'information d'origine
- Par analogie, une fois que l'on a vu le chameau de profil, le voir de face n'apporte pas beaucoup plus d'information...

➤ **Attention :**

- Dans le cas de l'ACP non-normée, chacune des variables représente *a priori* un poids égal à sa propre variance
- L'ACP non-normée est une application rare et en général, on travail avec la matrice des corrélations (ACP normée)

# Un cas simple à 2 variables

- Cas de l'ACP normée sur le même jeu de donnée :

$$C = \begin{pmatrix} 1 & 0.93 \\ 0.93 & 1 \end{pmatrix}$$

$$C - \lambda I = \begin{pmatrix} 1 - \lambda & 0.93 \\ 0.93 & 1 - \lambda \end{pmatrix}$$

$$\det(C - \lambda I) = (1 - \lambda)(1 - \lambda) - 0.93^2$$

$$\lambda^2 - 2\lambda + 0.1351 = 0$$


$$\Delta = b^2 - 4ac$$

$$\lambda_1 = \frac{-b + \sqrt{\Delta}}{2a} = 1.93$$

$$\lambda_1 = 1 + \rho$$

$$\lambda_2 = \frac{-b - \sqrt{\Delta}}{2a} = 0.07$$

$$\lambda_2 = 1 - \rho$$



# Un cas simple à 2 variables

➤ Une solution possible (cf. sous la contrainte que  $V_1$  et  $V_2$  soient tout 2 des vecteurs unitaires de taille 1)



$$V_1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \quad V_2 = \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \quad NB : v_{1,1}^2 + v_{1,2}^2 = 1$$
$$NB : v_{2,1}^2 + v_{2,2}^2 = 1$$

$$P = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}$$

$$D = \begin{pmatrix} 1+\rho & 0 \\ 0 & 1-\rho \end{pmatrix}$$

# Un cas simple à 2 variables

- $V_1$  et  $V_2$  sont les vecteurs directeur de  $CP_1$  et  $CP_2$  :



- $CP_1$  porte 96% de l'inertie totale du nuage de point
- NB :  $\rho(X_1, X_2) = 0.93$  mais  $\rho(CP_1, CP_2) = 0$

# Combien de composantes principales?

- L'ACP d'un tableau de données à  $P$  variables et  $N$  individus admet  $P$  valeurs propres,  $P$  vecteurs propres, et  $P$  composantes principales :
  - Conservez au moins 50-70% de la variance en cumulé
  - Conservez toutes les composantes principales dont  $\lambda > 1$  (limite de Kaiser)
  - Utilisez l'histogramme des valeurs propres (scree plot)
- Attention :
  - L'ACP sur un tableau de données tel que  $P > N$  est impossible

# Typologies des individus et des variables

## ➤ Typologie des individus :

- La lecture graphique de la position des individus le long des composantes principales permet de dresser une typologie
- Les individus proches le long d'une composante principale sont des individus qui partagent les mêmes caractéristiques vis-à-vis des variables quantitatives étudiées

## ➤ Typologie des variables :

- Chaque composante principale est une combinaison linéaire des variables de départ auxquelles sont affecté des poids
- La lecture graphique du cercle des corrélations permet de juger du poids des différentes variables de départ sur chacune des composantes principales


# Plan du cours

## Analyse en Composante Principale (ACP)

1. Définitions, applications et objectifs de l'ACP
2. Notion de covariance et ACP non-normée
3. Notion de corrélation et ACP normée
4. Mécanique de l'ACP à partir d'un exemple à deux variables
5. Application à partir d'un exemple concret (les forêts françaises)

# Exemple concret

- **Regrouper les départements français en régions homogènes du point de vue de la production forestière (typologie)**
- **12 variables relative à la production forestière dans 90 départements :**
  - Taux de boisement
  - Accroissement en volume par hectare
  - Volume par hectare
  - Taux de prélèvement
  - Taux de taillis
  - Part de propriété privé
  - Accroissement en volume / volume
  - Accroissement en surface / surface
  - Part de résineux (volume)
  - Indice d'exploitabilité
  - DQM
  - $\log(\text{volume} \geq \text{D60})$




Proportion de volume de bois sur pied de feuillus et résineux

- 0 à 20 % de feuillus, soit 80 à 100 % de résineux
- 20 à 40 % de feuillus, soit 60 à 80 % de résineux
- 40 à 60 % de feuillus, soit 40 à 60 % de résineux
- 60 à 80 % de feuillus, soit 20 à 40 % de résineux
- 80 à 100 % de feuillus, soit 0 à 20 % de résineux

Source IfN - campagnes 2005 à 2009

# Exemple concret

## ➤ Relations 2 à 2 entre variables :



# Exemple concret


## ➤ Matrice de corrélations :

	txBois	acV.ha	V.ha	Prelev.F	txTaillis	txPrive	txvarV	txvarS	txVres	i.exploit	DQM	logVs60
<b>txBois</b>	1	0,02	0,13	-0,12	-0,07	-0,31	0,04	-0,08	0,49	0,37	-0,07	-0,20
<b>acV.ha</b>	0,02	1	0,67	0,28	-0,49	0,02	-0,15	-0,19	0,16	-0,25	0,24	0,14
<b>V.ha</b>	0,13	0,67	1	0,31	-0,71	-0,50	-0,35	-0,35	0,03	-0,01	0,65	0,55
<b>Prelev.Prod</b>	-0,12	0,28	0,31	1	-0,15	-0,26	-0,79	-0,29	-0,06	-0,18	0,42	0,39
<b>txTaillis</b>	-0,07	-0,49	-0,71	-0,15	1	0,36	0,22	0,40	0,07	0,26	-0,60	-0,48
<b>txPrive</b>	-0,31	0,02	-0,50	-0,26	0,36	1	0,41	0,22	0,00	-0,14	-0,46	-0,42
<b>txvarV</b>	0,04	-0,15	-0,35	-0,79	0,22	0,41	1	0,59	0,09	-0,03	-0,47	-0,44
<b>txvarS</b>	-0,08	-0,19	-0,35	-0,29	0,40	0,22	0,59	1	0,11	0,15	-0,28	-0,22
<b>txVres</b>	0,49	0,16	0,03	-0,06	0,07	0,00	0,09	0,11	1	0,51	-0,16	-0,42
<b>i.exploit</b>	0,37	-0,25	-0,01	-0,18	0,26	-0,14	-0,03	0,15	0,51	1	-0,03	-0,10
<b>DQM</b>	-0,07	0,24	0,65	0,42	-0,60	-0,46	-0,47	-0,28	-0,16	-0,03	1	0,90
<b>logVs60</b>	-0,20	0,14	0,55	0,39	-0,48	-0,42	-0,44	-0,23	-0,42	-0,10	0,90	1

# Exemple concret

## ➤ Réalisation d'une ACP normée dans un espace à 12 dimensions :


- Décomposition de la variance sur les 12 composantes principales
- Combien d'axes doit-on conserver?



## Exemple concret

## ➤ Projection dans le plan ( $CP_1$ , $CP_2$ ) :

- ## ■ Position des départements et regroupement en types (typologie)



# Exemple concret

- Interprétation des axes du plan ( $CP_1$ ,  $CP_2$ ) :
  - Lecture du cercle des corrélations

